


# 100 题三臂 Paired 实验报告 ( v7 )

Qwen2.5-Math-7B-Instruct · RTX 4080 SUPER 32GB · MATH-500 level 4-5 前 100 题 · 512 窗口 + 复跑判定 · 2026-07-20

## 核心结论：rp=8 与 Fixed 逐题正确性零分歧，同时省 6.4% 算力

自适应停止在 rejection\_patience=8 下与固定 8 次重采样在 100 题上给出完全相同的逐题判定 ( 0 处分歧 )，准确率均为 69% ( 初始 67% )，同时仍比 Fixed 节省 6.4% token。rejection\_patience=4 更省算力 ( 15.9% ) 但会系统性错过救回：3 个真实的“错→对”修正中只抓住 1 个。首次出现的“对→错”经复核确认是判分脚本未剥离 \% 符号导致的假阴性，不是重采样引入的数学错误——五轮实验 ( v3-v7 ) 真实安全底线仍是 0 broken。唯一的短板：bootstrap 95% 置信区间跨零，100 题还不足以把方向性证据变成显著结论。



初始生成

67%

准确率基线  
723.8 token / 题

Fixed (8 步)

69%

省算力基准 ( 0% 早停 )  
2851.6 token / 题

Adaptive rp=8

69%

= Fixed 准确率, 省 6.4%  
2668.0 token / 题

重要限定：bootstrap 95% CI ( fixed/rp8 相对初始 ) 为 +2.0pp，区间 [-2.0pp, +6.0pp]，跨零——方向正确但 100 题样本量尚不足以在统计上确证准确率增益。下一步需要更大样本或更强效应量 ( 更宽窗口 / 更多重采样步数 ) 才能把方向性证据变成显著结论。

## 汇总指标（三臂，n=100）

| 方法            | 准确率 | 平均 token | 平均时间   | 拒绝 token 占比 | 接受率   | 早停率 |
|---------------|-----|----------|--------|-------------|-------|-----|
| 普通生成          | 67% | 723.8    | —      | —           | —     | —   |
| Fixed (8步)    | 69% | 2851.6   | 89.0 秒 | 50.1%       | 44.0% | 0%  |
| Adaptive rp=4 | 67% | 2397.8   | 76.8 秒 | 45.6%       | 44.4% | 52% |
| Adaptive rp=8 | 69% | 2668.0   | 83.8 秒 | 47.2%       | 46.4% | 24% |

## 统计检验（配对，n=100）

| 对比            | McNemar 分歧 (b10 / b01) | McNemar p 值 | 准确率差 · bootstrap 均值 | 95% 置信区间         |
|---------------|------------------------|-------------|---------------------|------------------|
| Fixed vs 初始   | 3 / 1                  | 0.625       | +2.0pp              | [-2.0pp, +6.0pp] |
| rp=4 vs 初始    | 1 / 1                  | 1.000       | +0.0pp              | [-3.0pp, +3.0pp] |
| rp=8 vs 初始    | 3 / 1                  | 0.625       | +2.0pp              | [-2.0pp, +6.0pp] |
| rp=4 vs Fixed | 0 / 2                  | 0.500       | -2.0pp              | [-5.0pp, 0.0pp]  |
| rp=8 vs Fixed | 0 / 0                  | —（零分歧）      | 0.0pp               | [0.0pp, 0.0pp]   |

## “对→错”复核：判分假阴性，非数学错误

index 28 ( dataset\_index 67，正方形改矩形面积变化题 )：三臂同时命中，标准答案“10”，初始生成\boxed{10} 判正确，重采样后 \boxed{10\%} 判错误——两者数学等价，现有 normalize\_answer 未剥离尾部 \% 导致误判。三臂命中同一题证明这不是重采样引入的数学错误，v3–v7 真实安全底线仍是 0 broken。

## “错→对”复核：3 例真实数值修正

| 题号 | dataset_index | 难度 | 标准答案 | 初始答案 | 最终答案 | Fixed | rp=4 | rp=8 |
|----|---------------|----|------|------|------|-------|------|------|
| 2  | 9             | 5  | 4    | 2    | 4    | ✓     | ✗    | ✓    |
| 25 | 62            | 5  | 4    | 5    | 4    | ✓     | ✗    | ✓    |
| 64 | 138           | 4  | 1/3  | 1/6  | 1/3  | ✓     | ✓    | ✓    |

rp=4 只抓住 q64，漏掉 q2、q25——与 v5/v6 ( 20 题 ) 观察到的“连续拒绝即停会砍掉救回”模式一致，100 题首次给出统计支持。

## 退化复跑判定效果

此前退化探针证实乱码退化（生成顶满预算、无 `\boxed{\}`）是种子依赖的随机事件，而非题目内在属性，据此实现了复跑判定：初始生成退化就换种子重试（默认最多 3 次），不改变 proposal 分布。

100 题中 11 题触发过复跑，10 题复跑后转为正常收尾（含 v5 中曾死重的两题），仅 1 题（dataset\_index 168）三次复跑后仍退化。死重率从 v5 的 10%（2/20）降到 v7 的 1%（1/100）。

## 省算力 vs 抓救回：权衡曲线

| 设置   | 相对 Fixed 省 token | 相对 Fixed 省时间 | 早停率 | 救回命中数（共 3）    |
|------|------------------|--------------|-----|---------------|
| rp=4 | 15.9%            | 13.7%        | 52% | 1             |
| rp=8 | 6.4%             | 5.8%         | 24% | 3（与 Fixed 相同） |

100 题给出的曲线比 v5/v6 的 20 题版本更平滑（此前 rp4 省 19.5% / rp8 省 4.6% 是小样本极端值）。rp=8 在这批题上实现了“零损失省算力”，是当前最值得作为默认配置的设置。

## 运行配置与环境

模型：Qwen/Qwen2.5-Math-7B-Instruct（BF16） | GPU：RTX 4080 SUPER 32GB  
题集：MATH-500 level 4–5，dataset\_index 可追溯，前 100 题 |  $\alpha=4.0$ ，seed=42+位置  
Fixed：8 次重采样 | Adaptive：min\_steps=2，patience=2，gain\_threshold=0.01，rejection\_patience $\in\{4,8\}$   
后缀窗口 512（较 v4 的 128 扩大 4 倍） | 退化复跑：最多 3 次换种子重试  
官方 CoT system prompt 经 chat template | 完整性护栏 + 答案护栏全程开启

## 建议的下一步

- 扩大样本至 200–300 题收窄置信区间，或先加大效应量（更宽窗口 / 更多重采样步数）再验证——纯堆样本量可能需要一整晚甚至更久，需先决定优先级。
- 视需要为 normalize\_answer 补充 `\%/%` 尾部剥离，修复本轮发现的判分假阴性（需用户确认）。
- 以 rp=8 为默认配置，视样本规模决定是否补 alpha（2 vs 4）与 gain\_threshold 对照。
- 与论文原文逐项核对 proposal distribution 与接受概率，再考虑接入难点优先选位。
- 样本规模与显著性问题解决后，再决定是否运行 MATH-500 全量（500 题）。

数据：results/fixed\_100\_w512.jsonl · adaptive\_100\_w512\_rp4.jsonl · adaptive\_100\_w512\_rp8.jsonl · hundred\_summary.json · hundred\_review.md 代码版本：5c29537（复跑判定）